

Déclinaison opérationnelle du back-testing des modèles de PD

LE : 8 décembre 2005

DE : RISQ/RCE/BEX

A : Equipes de modélisation du groupe SG

Objectifs : Dans le cadre de la validation interne des modèles, RISQ/RCE a diffusé en juin 2005 un protocole de back-testing, « protocole de back-testing RCE V6.pdf », permettant de formaliser les éléments techniques attendus ainsi que la démarche globale dans laquelle le back-testing s'inscrit. Cette note explicite les attendus pour le back-testing des modèles de PD retail tels que ceux développés par STMA, le Crédit du Nord ou Franfinance.

Table des matières

1	Cadre méthodologique	2
1.1	Eléments à back-tester	2
1.2	Maille élémentaire de back-testing	2
2	Mise en oeuvre opérationnelle	2
2.1	Back-testing de la structure de la population	2
2.2	Back-testing du calibrage des PD	3
2.3	Back-testing du score de classement	4
2.4	Synthèse des résultats	5
3	Annexe statistique	6
3.1	Indice de stabilité	6
3.2	Test binomial (test du calibrage)	6
3.3	Intervalles de confiance de l'AR	7
3.4	V de Cramer	7

1 Cadre méthodologique

1.1 Eléments à back-tester

Le modèle de PD a pour vocation d'affecter chaque client à un pool et d'attribuer à chaque pool une probabilité de défaut. Le back-testing, dont la fréquence est **a minima annuelle**, a pour objet de s'assurer que les méthodologies établies dans le passé pour évaluer la PD restent applicables et que le modèle de PD est toujours prédictif. En notant T la date (ou l'année) de construction du modèle et T' la date du back-testing, il s'agit donc de vérifier :

- **l'adéquation du modèle avec son périmètre d'application** en comparant la structure de la clientèle en T' à celle observée en T ;
- **le pouvoir prédictif du modèle** en comparant les taux de défaut observés à T' avec les taux prévus au moment du calibrage ;
- **la performance des scores en classement** dans le cas où l'attribution des pools repose sur une modélisation statistique.

Finalement, il s'agit de tester les caractéristiques de la population en entrée et les résultats en sortie, tout en vérifiant la cohérence globale du modèle. Le paragraphe 2 fournit quelques outils statistiques permettant de traiter ces points.

Le back-testing pourra être complété d'un stress-testing et, dans la mesure du possible, d'un benchmarking.

1.2 Maille élémentaire de back-testing

Dans le cadre du back-testing du modèle de PD, plusieurs niveaux d'analyse sont envisageables. Le back-testing pourra être effectué jusqu'à la **maille élémentaire produit/pool**. Concrètement :

- la stabilité de la structure de la clientèle doit être étudiée par sous-population identifiée lors de la construction du modèle de PD ;
- le calibrage des PD doit être vérifié par produit, pour chaque pool, et globalement pour l'ensemble de la population à la date du back-testing T' et pour chaque sous-population ;
- la qualité des scores est mesurée par produit sur chaque population sur laquelle ils s'appliquent.

Dans le cas où les effectifs des populations sur lesquelles porte le back-testing seraient élevés, il sera possible de travailler sur des **échantillons représentatifs** plutôt que sur la population complète.

2 Mise en oeuvre opérationnelle

2.1 Back-testing de la structure de la population

Il est important de vérifier que la structure du portefeuille n'a pas sensiblement varié. En effet, si la population à laquelle on applique le modèle diffère de la population qui a servi à le construire,

il est possible que les résultats se dégradent. On examinera ainsi la conformité de la population issue des bases de back-testing avec le périmètre d'application du modèle défini au moment de son élaboration.

Lors de la construction du modèle, une étude de représentativité de l'échantillon avait été effectuée¹. La stabilité de la population de back-testing pourra être étudiée selon des axes d'analyse similaires à ceux retenus lors de cette étude. Par exemple, pour une analyse effectuée selon les axes CSP, âge et ancienneté, on pourra notamment étudier l'indice de stabilité (IS) de chacune de ces variables. On pourra également envisager un test de comparaison des proportions pour chaque axe d'analyse.

On pourra formaliser les résultats comme suit :

	IS pour l'axe 1	...	IS pour l'axe n
Population 1			
...			
Population p			

2.2 Back-testing du calibrage des PD

Lors du calibrage, on a attribué à chaque pool une probabilité de défaut $\widehat{PD}_i$ ². Cet estimateur peut être égal au taux moyen de défaut au sein du pool ou à un majorant du taux moyen. On doit donc s'assurer que $\widehat{PD}_i$ est un bon estimateur de la PD. Pour cela, on vérifie que le taux de défaut observé sur la population de back-testing, noté τ_{obs} , est bien cohérent avec la probabilité de défaut retenue au moment du calibrage³.

De nombreux tests permettent de répondre à cette question. On pourra retenir le test binomial⁴. Celui-ci compare le nombre de défauts observés au nombre de défauts théoriques si la vraie valeur de PD était bien $\widehat{PD}$. Si le nombre de défauts est dans l'intervalle de confiance défini par le test, on peut considérer a posteriori que la PD est correctement calibrée au sein du pool. Dans le cas contraire, le test des feux de circulation⁵, moins exigeant que le test binomial, pourra être mis en oeuvre afin d'affiner le jugement.

Comme il est équivalent de raisonner sur le nombre de défauts ou sur le taux de défaut du pool, on pourra synthétiser les résultats comme suit :

¹Notamment, une étude de la représentativité de la population d'application par rapport à la population de construction lorsqu'elle est plus ancienne a été réalisée.

²Cf. fiche technique « Calibrage des PD V02.pdf » diffusée en octobre 2005.

³La comparaison entre $\widehat{PD}$ et τ_{obs} se fera à périmètre et mode de calcul identiques. Notamment, si $\widehat{PD}$ est calculé en intégrant les entrées dans l'année n , une analyse sera également obtenue en appliquant cette méthode.

⁴Cf. annexe 3.2.

⁵Cf. article « Traffic Light Approach » inséré en annexe 2 du document « protocole de back-testing RCE V6.pdf ».

	Probabilité de défaut calibrée	τ_{obs}	Comparaison de τ_{obs} et de l'intervalle de confiance binomial construit à partir de la PD calibrée	Résultat du test des feux de circulation
Pool 1	$\widehat{PD}_i$	D_i/N_i	Le taux de défaut est-il dans l'IC, au-delà de la borne supérieure ou en deçà de la borne inférieure ?	Uniquement si nécessaire
...				
Pool P				
Global	$\widehat{PD}$	$\frac{\sum_i D_i}{\sum_i N_i}$		

où :

- D_i est le nombre de dossiers du pool i tombés en défaut au cours de l'année précédant T' et sains en T'-1 an ;
- N_i est le nombre total de dossiers du pool i sains à T'-1 an.

2.3 Back-testing du score de classement

Le back-testing du classement est mis en oeuvre dans le seul cas où un ou plusieurs scores sont employés pour classer la population par niveau de risque. Il s'agit alors d'examiner la qualité et la performance de ce ou ces scores en classement.

Théoriquement, ce niveau de back-testing devrait donc porter sur deux aspects : le classement induit par le score et les variables qui le définissent. Néanmoins, le back-testing des variables implique un grand nombre de traitements statistiques. En outre, ici, l'enjeu est non pas de vérifier que le score est bien construit mais qu'il est efficace. C'est pourquoi **le back-testing des variables est envisagé uniquement lorsque le back-testing du caractère discriminant du classement n'est pas satisfaisant.**

2.3.1 Back-testing du caractère discriminant du classement

Il s'agit de vérifier que le classement distingue toujours bien défaillants et non défaillants pour **l'ensemble de la population sur laquelle le score s'applique**. On pourra employer les indicateurs statistiques de performance retenus lors de la construction du score, l'AR par exemple, et comparer leurs valeurs calculées à partir du défaut bâlois sur la population de back-testing (T') et sur la génération de construction (T). Si la performance demeure à un niveau acceptable, il sera possible d'affirmer que le classement demeure discriminant.

Le seuil en-deçà duquel le score n'est plus considéré comme satisfaisant pourra être fixé :

- soit qualitativement ;

- soit quantitativement, à partir d'intervalles de confiance établis lors de la construction du modèle⁶.

On pourra donc formaliser les résultats comme suit :

	Valeur de l'indicateur de performance	
	A la construction T	Au back-testing T'
Population 1		
Population 2		
...		
Population p		
Global*		

** Résultats à fournir uniquement si l'indicateur est calculé pour l'ensemble de la population à la construction.*

2.3.2 Back-testing des variables

Si le classement semble peu satisfaisant, une analyse approfondie des variables du score devrait être menée sur la seule **population de construction du score**. Pour vérifier le caractère discriminant de chaque variable et sa stabilité, on pourra utiliser les mêmes indicateurs que ceux employés à la construction : les indicateurs qualitatifs (graphes, tableaux de répartition, etc.) et quantitatifs⁷.

Pour la population de construction du score, pour les variables qualitatives⁸, on pourra également :

- calculer le V de Cramer⁹ entre l'indicatrice du défaut et chaque variable explicative pour vérifier l'aspect discriminant de la variable ;
- calculer l'indice de stabilité¹⁰ pour vérifier la stabilité de la variable au cours du temps.

Ces résultats pourront par exemple être formalisés comme suit :

⁶Une méthode d'obtention d'un intervalle de confiance pour l'Accuracy Ratio (AR) est proposée en annexe 3.3.

⁷Cf. annexe 3 du document « Protocole de validation RCE.pdf » diffusé en mai 2004.

⁸Dans le cas où une ou plusieurs variables quantitatives seraient prises en compte dans le score, on pourra les discrétiser, par exemple en employant un découpage en fractiles.

⁹Cf. annexe 3.4.

¹⁰Cf. annexe 3.1.

		Valeur du V de Cramer	Valeur de l'indice de stabilité
Population 1	Variable 1		
	...		
	Variable v		
...			
Population p	Variable 1		
	...		
	Variable v		
Global	Variable 1		
	...		
	Variable v		

2.4 Synthèse des résultats

Au-delà des résultats chiffrés et pour chaque étape, les différents éléments du back-testing seront commentés dans le livrable dédié. Cela permettra à la Branche d'identifier les éventuels points de faiblesse du modèle de PD. En fonction des résultats, le mode de suivi et éventuellement une liste d'actions correctrices seront définis, conformément aux exigences du comité de Bâle et à la démarche exposée dans le protocole général de back-testing¹¹.

¹¹Cf. §2 du document « Protocole de back-testing RCE V6.pdf » diffusé en juin 2005.

3 Annexe statistique

3.1 Indice de stabilité

Une population peut être considérée comme stable par rapport à une variable qualitative si la répartition de cette population par modalité change peu. L'indice de stabilité est un indicateur synthétique des écarts de répartition entre deux dates. En notant P_n le poids de la modalité n au sein de la population initiale et B_n le poids de la modalité n au sein de la population de back-test,

$$\left(\sum_{m=1}^M P_m = \sum_{m=1}^M B_m = 1 \right),$$

on peut récapituler les écarts de répartition dans un tableau comme suit :

	Population initiale	Population de back-testing
Modalité 1	P_1	B_1
...		
Modalité M	P_M	B_M

L'indice de stabilité est alors déterminé par la formule suivante :

$$IS = \sum_{m=1}^M (P_m - B_m) \ln \left(\frac{P_m}{B_m} \right).$$

A titre de référence, l'indice de stabilité est souvent comparé dans la littérature aux seuils suivants :

- si $IS > 0,1$, l'instabilité peut être qualifiée de moyenne ;
- si $IS > 0,3$, l'instabilité peut être qualifiée de forte.

Pour calculer l'indice de stabilité sur des variables continues, on pourra utiliser comme classe de variable des quantiles.

3.2 Test binomial (test du calibrage)

On considère que la probabilité de défaut prédite ($\widehat{PD}$) pour une classe est bonne si le taux de défaut observé est compris entre :

$$\widehat{PD} - \Phi^{-1}(\alpha) \sqrt{\frac{\widehat{PD}(1 - \widehat{PD})}{n}} \quad \text{et} \quad \widehat{PD} + \Phi^{-1}(\alpha) \sqrt{\frac{\widehat{PD}(1 - \widehat{PD})}{n}},$$

où α est le niveau de précision requis (par exemple pour $\alpha = 95\%$, alors $\Phi^{-1}(\alpha) = 1,96$; si $\alpha = 99\%$, $\Phi^{-1}(\alpha) = 2,33$) et n le nombre d'individus de la classe.

Si, pour le niveau de précision requis α , le taux de défaut observé sur la population de back-testing est proche de l'une des bornes de l'intervalle de confiance, on pourra reprendre le test avec un autre niveau de précision α' afin de préciser le jugement.

Ce test repose sur une approximation asymptotique de la loi binomiale par la loi normale¹². Il est également fondé sur l'hypothèse de défauts indépendants, dont il est difficile de savoir si elle est vérifiée. Néanmoins, ce test est conservateur lorsque cette hypothèse n'est pas vérifiée. Le test binomial peut donc être considéré comme un système de détection précoce des anomalies : un refus de H_0 ne saurait signifier que les probabilités de défaut prédites sont mauvaises. En revanche, si H_0 est acceptée, on peut considérer que le calibrage est satisfaisant.

3.3 Intervalles de confiance de l'AR

L'Accuracy Ratio (AR) permet de quantifier la qualité d'un score. D'autres indicateurs existent comme la mesure Receiver Operating Characteristic (ROC). Cette dernière a été l'objet de développements récents montrant qu'il est possible de déterminer un intervalle de confiance de la mesure ROC¹³. L'AR et le ROC étant liés par la relation $AR = 2ROC - 1$, on peut en déduire un encadrement de l'AR centré sur l'AR obtenu lors de la construction :

$$I(AR)_\alpha = \left[AR_T - \hat{\sigma}_{AR} \Phi^{-1} \left(\frac{1 + \alpha}{2} \right), AR_T + \hat{\sigma}_{AR} \Phi^{-1} \left(\frac{1 + \alpha}{2} \right) \right]$$

où AR_T est l'AR calculé lors de la construction du modèle (en T), $\hat{\sigma}_{AR}^2$ est un estimateur de la variance de l'AR, α le niveau de confiance (95% ou 99% par exemple) et Φ la fonction de répartition de la loi normale centrée réduite. Il est à noter que l'on dispose d'un majorant de $\hat{\sigma}_{AR}^2$ puisque :

$$\hat{\sigma}_{AR}^2 \leq \frac{1 - AR_T^2}{\min(N_D, N_{ND})}.$$

avec N_D le nombre de défaillants et N_{ND} le nombre de non défaillants lors de la construction du modèle (en T). Ce majorant de la variance est très faible lorsque l'on dispose d'un grand nombre d'observations défaillantes dans l'échantillon.

Pour obtenir l'intervalle de confiance exact, on pourra se reporter au working paper « Improving the Comparability of Insolvency Predictions » publié par Martin Bemmman le 23/06/2005 sur l'étude des performances des modèles de PD.

3.4 V de Cramer

La statistique du χ^2 mesure le niveau de dépendance entre deux variables qualitatives X et Y . Si X a r modalités et Y a c modalités (r = row nombre de lignes ; c = column nombre de colonnes), qu'on note N le nombre total d'individus, n_{ij} le nombre d'individus prenant la modalité i de la variable X et la modalité j de la variable Y , n_i le nombre d'individus prenant la modalité i de la variable X et n_j le nombre d'individus prenant la modalité j de la variable Y , elle vaut :

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{\left(n_{ij} - \frac{n_i \times n_j}{N} \right)^2}{\frac{n_i \times n_j}{N}}.$$

Cette statistique permet certes de tester l'indépendance de deux variables ; néanmoins, elle ne permet pas de déterminer un degré de liaison et est fortement dépendante du nombre de modalités et du nombre d'observations. Le V de Cramer permet en quelque sorte une normalisation de

¹²Dans le cadre du retail, cette approximation se justifie le plus souvent grâce au théorème central limite ou à l'approximation de la loi binomiale par la loi normale.

¹³Cf. « Working paper 14 » inséré en annexe 1 du document « protocole de back-testing RCE V6.pdf ».

cette statistique puisqu'il vaut :

$$V = \sqrt{\frac{\chi^2}{\chi_{max}^2}} = \sqrt{\frac{\chi^2}{N \times [\min(r, c) - 1]}}.$$

En fonction des valeurs du V de Cramer, on peut déterminer l'intensité de la relation entre X et Y : plus V est élevé, plus les variables sont dépendantes.